

Progetto EGO-CH — Deep Learning

Relazione Finale

Nome Cognome

Nome Cognome

Nome Cognome

Anno Accademico 2025/2026

Indice

1	Introduzione	3
1.1	Contesto e Motivazione	3
1.2	La Visione Egocentrica nei Beni Culturali: Sfide Tecniche	3
1.3	Obiettivi della Ricerca e Struttura della Relazione	4
2	Il Dataset EGO-CH	6
2.1	Protocollo di Acquisizione e Hardware	6
2.2	I Siti Culturali e Statistiche Dettagliate	6
2.2.1	Palazzo Bellomo (Siracusa)	6
2.2.2	Monastero dei Benedettini (Catania)	7
2.3	Struttura delle Annotazioni	7
2.4	Analisi della Complessità e delle Criticità del Dominio	8
3	Task 1 — Room-based Localization	9
3.1	Definizione del Problema	9
3.2	La Baseline del Paper Originale	9
3.3	Analisi del Dataset e Sfide Iniziali	9
3.3.1	Esclusione del Monastero dei Benedettini	9
3.3.2	Le Sfide del Dataset Palazzo Bellomo	10
3.4	Estrazione delle Feature: Il Ruolo di DINOv2	10
3.4.1	Perché DINOv2?	11
3.4.2	Pipeline di Estrazione Offline e Ottimizzazione della Memoria	11
3.5	Modellazione Temporale con Mamba	12
3.5.1	Modello V1: Mamba Base	12
3.5.2	Modello V2: Weighted Loss e Label Smoothing	12
3.5.3	Modello V3 Experimental: MS-TCN e MLP	13
3.6	Discussione	13
4	Task 2 — Point of Interest Recognition	14
4.1	Definizione del Problema	14
4.2	La Baseline del Paper Originale	14
4.2.1	Architettura e Protocollo	14
4.2.2	Risultati del Paper (Tabella 4)	14
4.2.3	Analisi delle Difficoltà Evidenziate	15
4.3	La Nostra Proposta: YOLOv8	15
4.3.1	Motivazione della Scelta Architettureale	15
4.3.2	Approccio End-to-End	16
4.4	Pipeline Implementativa	16
4.4.1	Fase 1: Preprocessing e Riformattazione del Dataset	16

4.4.2	Fase 2: Training	17
4.5	Esperimenti e Risultati	18
4.5.1	Setup Sperimentale	18
4.5.2	Risultati Quantitativi	18
4.5.3	Curve di Addestramento	19
4.5.4	Analisi Qualitativa	20
4.5.5	Matrice di Confusione	20
4.6	Discussione	21
4.6.1	Confronto con la Baseline del Paper	21
4.6.2	Nota sulla Comparabilità delle Metriche	22
4.6.3	Trade-off Efficienza–Accuratezza	22
5	Task 3 — Object Retrieval	23
5.1	Definizione del Problema	23
5.1.1	Formulazione One-Shot Retrieval	23
5.1.2	Le Sfide del Domain Shift	23
5.2	La Baseline del Paper Originale	24
5.2.1	Architettura e Metodologia	24
5.2.2	Risultati del Paper (Tabella 5)	24
5.2.3	Criticità della Baseline	24
5.3	La Nostra Proposta: DINOv2 e Matching Latente	25
5.3.1	Motivazione dell'Estrattore Vision Transformer	25
5.3.2	Metriche di Matching: Cosine Similarity	25
5.4	Pipeline Implementativa	25
5.5	Esperimenti e Risultati	26
5.6	Discussione e Analisi Comparativa	26
5.6.1	Risoluzione del Domain Shift mediante SSL	27
5.6.2	Efficienza Computazionale e Spaziale	27
5.6.3	Impatto della Scalabilità e della Complessità dei Siti	27
6	Conclusioni	28

Capitolo 1

Introduzione

1.1 Contesto e Motivazione

Negli ultimi anni, la convergenza tra le tecnologie indossabili (*wearable devices*) e l'Intelligenza Artificiale ha aperto nuove prospettive nel campo della fruizione del patrimonio culturale (*Augmented Cultural Heritage*). La **Egocentric Vision** (o *First-Person Vision*, FPV) si differenzia radicalmente dalla visione artificiale classica a telecamera fissa: catturando il mondo dalla prospettiva diretta dell'utente («what the user sees is what the camera captures»), offre una finestra privilegiata sulle dinamiche di esplorazione, l'attenzione visiva e il comportamento spontaneo dei visitatori all'interno di musei e siti archeologici.

Il presente lavoro di tesi e ricerca si colloca nell'ambito dei progetti nazionali e regionali **VEDI** (*Vision Exploitation for Data Interpretation*) e **VALUE** (*Visual Analysis for Localization and Understanding of Environments*), sviluppati dall'Image Processing Laboratory (IPLab) dell'Università di Catania in collaborazione con il centro di ricerca CUTGANA e partner industriali. L'obiettivo primario di tali iniziative è la creazione di sistemi di assistenza intelligente per visitatori (es. guide virtuali contestuali ed egocentriche) e di strumenti avanzati di business intelligence per i curatori museali, capaci di analizzare in tempo reale i percorsi di visita, i tempi di permanenza di fronte alle opere e il gradimento complessivo dell'esperienza culturale.

1.2 La Visione Egocentrica nei Beni Culturali: Sfide Tecniche

L'elaborazione automatica di video egocentrici acquisiti in contesti museali «in-the-wild» presenta una serie di sfide metodologiche estremamente complesse, che rendono inadeguati gli approcci convenzionali di Computer Vision:

- **Ego-Motion e Motion Blur:** i movimenti naturali, rapidi e incontrollati del capo del visitatore introducono continue variazioni del punto di vista, inclinazioni della linea d'orizzonte e vistose sfocature da movimento (*motion blur*).
- **Condizioni Illuminotecniche Cangianti:** le visite reali si svolgono nell'arco di intere giornate e stagioni differenti, esponendo le telecamere a sbalzi continui tra luce solare diretta (es. cortili o finestre), penombra di sale espositive e riflessi artificiali sui vetri di protezione delle opere.

- **Occlusioni Parziali e Prospettive Sghembe:** le opere d’arte vengono frequentemente inquadrare da angolazioni fortemente prospettiche, a distanze ravvicinate o parzialmente coperte dal passaggio di altri visitatori.
- **Riconoscimento a livello di Istanza (*Instance-Level Recognition*):** a differenza dei benchmark di object detection tradizionali (es. COCO, Pascal VOC) incentrati sulla categorizzazione di classi generiche (es. “persona”, “sedia”), nei beni culturali il sistema deve discriminare tra *singole istanze* visivamente affini (es. dipinti sacri dello stesso artista, affreschi del medesimo periodo storico o dettagli decorativi analoghi).

1.3 Obiettivi della Ricerca e Struttura della Relazione

Per stimolare la ricerca e fornire un benchmark di riferimento per la comunità scientifica, Ragusa et al. [1] hanno introdotto il dataset **EGO-CH**, definendo quattro task fondamentali per la comprensione del comportamento del visitatore:

1. **Task 1 — Room-based Localization:** la localizzazione frame-per-frame e la tracciatura sequenziale dell’ambiente (stanza) in cui si trova il visitatore all’interno del sito culturale.
2. **Task 2 — Point of Interest (POI) Recognition:** il rilevamento spaziale (*object detection* tramite bounding box 2D) e la classificazione dei Punti di Interesse visibili nel campo visivo.
3. **Task 3 — Object Retrieval:** il recupero dell’immagine di riferimento pulita di un’opera d’arte a partire da una patch ritagliata da una query egocentrica (*One-Shot Retrieval*).
4. **Task 4 — Survey Prediction:** la predizione automatica del questionario di gradimento e memoria compilato dal visitatore al termine della visita, basata sull’analisi del video egocentrico.

L’obiettivo fondamentale della presente relazione è quello di superare i limiti delle baseline storiche proposte nel paper originale del 2020 (basate su architetture ormai datate quali VGG19, K-NN e YOLOv3), introducendo una pipeline di **Deep Learning di ultima generazione**.

In particolare, abbiamo sfruttato l’espressività dei **Foundation Model basati su Vision Transformer (DINOv2)**, l’efficienza dei modelli di sequenza a spazio di stato (**Mamba SSM**) e la precisione dei moderni detector anchor-free (**YOLOv8**), stabilendo il nuovo stato dell’arte su tutti e tre i task fondamentali del benchmark EGO-CH senza modificare il protocollo di valutazione originale.

La relazione è strutturata come segue:

- Il **Capitolo 2** descrive in dettaglio l’architettura del dataset **EGO-CH**, i protocolli di acquisizione hardware, i due siti culturali considerati e la struttura delle annotazioni.
- Il **Capitolo 3** affronta il **Task 1 (Room-based Localization)**, presentando la pipeline basata su feature DINOv2 e sequence modeling temporale con Mamba.
- Il **Capitolo 4** analizza il **Task 2 (Point of Interest Recognition)**, illustrando l’approccio end-to-end con YOLOv8 nelle varianti Nano e X-Large.

- Il **Capitolo 5** presenta il **Task 3 (Object Retrieval)**, descrivendo il matching nello spazio latente di DINOv2 mediante Cosine Similarity e la risoluzione del *Domain Shift*.
- Il **Capitolo 6** trae le **Conclusioni** finali e sintetizza i contributi complessivi del lavoro.

Capitolo 2

Il Dataset EGO-CH

2.1 Protocollo di Acquisizione e Hardware

Il dataset **EGO-CH** (*Egocentric Cultural Heritage*) [1] è un benchmark di riferimento per la visione egocentrica nei beni culturali, progettato e raccolto dal gruppo di ricerca IPLab dell’Università di Catania.

Le acquisizioni sono state condotte impiegando visori indossabili **Microsoft HoloLens** di prima generazione, montati sulla testa dei partecipanti. Questo dispositivo permette di registrare il flusso video egocentrico garantendo che il centro della fotocamera sia costantemente allineato con la direzione prevalente dello sguardo dell’utente.

La campagna di acquisizione ha coinvolto un totale di **70 soggetti distinti**, suddivisi tra volontari (per le sessioni di addestramento) e **60 visitatori reali** non guidati (per le sessioni di test e valutazione comportamentale). Le riprese sono state distribuite nell’arco di **oltre tre mesi**, consentendo di catturare una naturale ed estesa variabilità delle condizioni ambientali (affollamento, illuminazione diurna e artificiale, percorsi di esplorazione non vincolati). Complessivamente, il dataset raccoglie **oltre 27 ore di video egocentrici ad alta risoluzione**.

2.2 I Siti Culturali e Statistiche Dettagliate

Le acquisizioni si sono svolte all’interno di due importanti ed eterogenei siti culturali situati in Sicilia:

2.2.1 Palazzo Bellomo (Siracusa)

La Galleria Regionale di Palazzo Bellomo a Siracusa ospita una vasta collezione d’arte medievale e moderna, disposta in una struttura architettonica complessa e articolata.

- **Ambienti (Stanze):** 22 sale espositive distinte.
- **Points of Interest (POI):** 191 oggetti di interesse annotati (principalmente dipinti, sculture, iscrizioni e manufatti d’arte).
- **Video di Training:** 57 clip video di breve durata (media di 1.4 minuti per clip), incentrate su specifici POI o ambienti.
- **Video di Test:** 10 sequenze video continue a risoluzione 1280×720 pixel @ 29.97 fps, con una durata media di 31.3 minuti ciascuna, corrispondenti a visite integrali.
- **Annotazioni Spaziali:** 70.088 frame annotati manualmente con bounding box 2D.

- **Query Patch:** 23.727 immagini ritagliate dalle bounding box dei POI nei video di test.
- **Gallery di Riferimento:** 191 fotografie ufficiali da catalogo dei POI (1 immagine di alta qualità per ciascun POI).

2.2.2 Monastero dei Benedettini (Catania)

Il Monastero di San Nicolò l’Arena a Catania è un complesso monumentale tardo-barocco (patrimonio UNESCO) caratterizzato da ampi spazi architettonici.

- **Ambienti (Stanze):** 4 macro-ambienti espositivi e di transito (Antirefettorio, Refettorio Grande, Corridoio dell’Orologio, Chiostro).
- **Points of Interest (POI):** 35 POI annotati. A differenza di Palazzo Bellomo, qui i POI comprendono sia opere d’arte che complessi **elementi architettonici** (es. portali monumentali, archi, pavimenti maiolicati, corridoi e scaloni).
- **Video di Training e Validation:** 48 video di training e 5 video di validation a risoluzione 1216×684 pixel @ 24 fps.
- **Visite Reali di Test:** 60 video di visite integrali condotte da 60 visitatori reali a risoluzione 1408×792 pixel @ 30.03 fps.
- **Annotazioni Spaziali:** 106.911 frame annotati con bounding box 2D.
- **Query Patch:** 44.978 immagini ritagliate dalle bounding box nei video di test.
- **Gallery di Riferimento:** 35 immagini di riferimento ufficiali dei POI.
- **Sondaggi (Surveys):** 60 questionari completi di gradimento e memoria dei POI compilati dai visitatori al termine della visita.

La Tabella 2.1 sintetizza la struttura quantitativa dei due siti culturali appartenenti al benchmark.

Tabella 2.1: Statistiche riassuntive del dataset EGO-CH per i due siti culturali.

Proprietà	Palazzo Bellomo (Siracusa)	Monastero dei Benedettini (Catania)
Ambienti (Stanze)	22	4 (5 etichette test)
Points of Interest (POI)	191	35
Soggetti coinvolti	Volontari + Test	60 visitatori reali
Risoluzione Video	1280×720	1216×684 / 1408×792
Frame annotati (BB)	70.088	106.911
Patch visive estratte (Query)	23.727	44.978
Immagini Gallery (One-Shot)	191	35
Sondaggi associati	—	60 questionari reali

2.3 Struttura delle Annotazioni

Il dataset EGO-CH fornisce annotazioni ricche e multi-livello per supportare i diversi task di machine learning:

1. **Annotazioni Temporalì (*Room e POI level*):** per ogni fotogramma t dei video di visita, un file di annotazione specifica in quale stanza si trova il visitatore e se sta osservando direttamente uno dei POI codificati.

2. **Annotazioni Spaziali (Bounding Boxes 2D)**: per i fotogrammi in cui sono visibili POI, sono fornite le coordinate rettangolari $(x_{\min}, y_{\min}, x_{\max}, y_{\max})$ che delimitano la posizione dell'oggetto nel frame.
3. **Annotazioni di Sondaggio (*Surveys*)**: per le 60 visite del Monastero, ciascun visitatore ha indicato in un questionario finale se ricordava di aver visto ciascuno dei 35 POI e ha assegnato un punteggio di gradimento su una scala discreta da -7 a $+7$.

2.4 Analisi della Complessità e delle Criticità del Dominio

L'analisi dei dati di EGO-CH mette in luce diverse criticità intrinseche che hanno guidato le nostre scelte architettoniche:

- **Distribuzione a Coda Lunga (*Long-Tail Distribution*)**: la durata della permanenza dei visitatori di fronte ai diversi POI o nelle diverse sale è fortemente sbilanciata. Alcune opere principali accumulano decine di migliaia di fotogrammi, mentre oggetti secondari o zone di transito compaiono per pochi secondi.
- **Rischio di Data Leakage**: la presenza nel dataset di sia video di stanze intere che sotto-clip ritagliate comporta la duplicazione intrinseca di migliaia di fotogrammi, imponendo la progettazione di meccanismi di deduplicazione nei DataLoader per prevenire l'overfitting.
- **Ambiguità Semantica degli Elementi Architettonici**: nel Monastero dei Benedettini, molti POI (es. corridoi, archi, pavimenti) non possiedono confini definiti e variano continuamente in prospettiva e scala durante il cammino del visitatore, rendendo fallaci le normali euristiche di detection basate su rettangoli chiusi.

Capitolo 3

Task 1 — Room-based Localization

3.1 Definizione del Problema

Il Task 1, denominato *Room-based Localization*, consiste nell'identificare in quale stanza si trovi il visitatore, frame per frame, analizzando il video egocentrico. Poiché il video cattura l'esplorazione sequenziale degli ambienti, questo task è a tutti gli effetti un problema di **video understanding** e analisi di serie temporali, dove la coerenza temporale delle predizioni riveste un ruolo cruciale.

3.2 La Baseline del Paper Originale

Gli autori di EGO-CH affrontano il Task 1 estraendo caratteristiche visive (feature) con **VGG19** pre-addestrato su ImageNet, per poi classificarle frame per frame utilizzando l'algoritmo K-Nearest Neighbors (KNN). Per correggere l'incoerenza temporale delle predizioni (effetto *flickering*), applicano un modello di Markov Nascosto (Hidden Markov Model, HMM) come step di post-processing. Sul dataset del Palazzo Bellomo, la baseline del paper ottiene:

- **FF1 (Frame-Level F1-Score)**: 0.8100
- **ASF1 (Action Segment F1-Score)**: 0.5900

3.3 Analisi del Dataset e Sfide Iniziali

Il punto di partenza per il Task 1 è consistito in un'attenta analisi dei due dataset forniti dagli autori: Palazzo Bellomo e Monastero dei Benedettini. Fin dalle prime fasi di esplorazione dei dati, sono emerse criticità significative legate alla struttura e alla qualità delle annotazioni.

3.3.1 Esclusione del Monastero dei Benedettini

Il dataset del Monastero dei Benedettini presentava incongruenze strutturali insormontabili che lo rendevano del tutto inadatto per un addestramento e una valutazione affidabili. Durante la fase di esplorazione preliminare dei dati sono emerse le seguenti gravi anomalie:

- **Incompatibilità dei sistemi di etichettatura (Label Mismatch)**: Analizzando i file di ground truth, abbiamo scoperto che il set di *Training* assegnava alle stanze etichette numeriche nel range [5, 8], mentre i set di *Validation* e *Test* utilizzavano

un sistema completamente disgiunto nel range $[0, 4]$. Questo disallineamento rende impossibile la valutazione zero-shot di un modello, poiché verrebbe addestrato a predire classi inesistenti nel test set.

- **Dati mancanti nel set di addestramento:** Il README ufficiale del dataset dichiara la presenza di 5 ambienti (*environments*) per il Monastero. Tuttavia, la cartella del Training set fornita contiene solo 4 stanze (etichettate 5, 6, 7 e 8). La presenza di 5 classi uniche (da 0 a 4) nei file di Test e Validation conferma che un intero ambiente è stato inavvertitamente omesso dal set di training distribuito.
- **Mancanza di coerenza temporale continua:** A differenza di Palazzo Bellomo, che offre sequenze video intere associate a un’etichetta univoca della stanza, i video del Monastero risultavano frammentati e organizzati più in ottica di *Point of Interest* che di vera e propria esplorazione ambientale continua.

A fronte di questi difetti fondamentali a livello di integrità del dataset, che avrebbero invalidato qualsiasi risultato sperimentale, abbiamo deciso metodologicamente di escludere il Monastero dei Benedettini. L’intera fase di ricerca, addestramento e test si è dunque focalizzata esclusivamente sul dataset di **Palazzo Bellomo**, il quale si è dimostrato robusto e coerente, comprendendo 22 stanze distinte esplorate in continuità.

3.3.2 Le Sfide del Dataset Palazzo Bellomo

Nonostante la struttura più coerente, il dataset di Palazzo Bellomo nascondeva insidie insite nella natura stessa dei video egocentrici e nella strutturazione dei file:

- **Sbilanciamento Estremo (Long-tail distribution):** Alcune stanze (es. corridoi di transito) venivano attraversate dal visitatore in pochissimi secondi, generando un numero esiguo di frame di addestramento; altre sale ampie (es. le gallerie d’arte) venivano esplorate per svariati minuti. Questo grave sbilanciamento delle classi rappresenta una sfida critica, poiché i modelli tendono a ignorare le classi minoritarie.
- **Motion Blur e Ambiguità Visiva:** I movimenti continui e bruschi della testa generano sfocature marcate. Inoltre, l’utente scatta spesso lo sguardo verso il pavimento o il soffitto (zone prive di elementi distintivi), rendendo ambiguo il contesto visivo e introducendo rumore *intra-classe*.
- **Duplicazione intrinseca dei Dati (Data Leakage):** Il dataset forniva video a due livelli di granularità: intere stanze (*room-level*) e brevi sotto-sequenze incentrate su singole opere (*video-clip*). Essendo queste ultime ritagli dei video principali, caricare l’intero dataset avrebbe comportato l’elaborazione di migliaia di frame duplicati, falsando il training e favorendo un forte *overfitting*. Per arginare il problema, abbiamo implementato un sistema di de-duplicazione dinamica nel *DataLoader*, istruito per filtrare e scartare in automatico le sotto-clip ridondanti laddove fosse presente il corrispettivo file *room-level* aggregato.

3.4 Estrazione delle Feature: Il Ruolo di DINOv2

Per affrontare le estreme ambiguità visive dei video egocentrici, era imperativo abbandonare l’estrattore statico utilizzato nel paper originale (VGG19, una convoluzionale addestrata per classificazione di immagini) a favore di un foundation model capace di una com-

preensione semantica profonda e globale della scena. La scelta è ricaduta su **DINOv2** [4], un modello *Vision Transformer* sviluppato da Meta AI.

3.4.1 Perché DINOv2?

A differenza delle classiche reti addestrate in modo supervisionato su ImageNet (il cui obiettivo è riconoscere l'oggetto dominante), DINOv2 è stato addestrato tramite **Self-Supervised Learning** (apprendimento auto-supervisionato) su un gigantesco corpus di 142 milioni di immagini non etichettate. Questo paradigma conferisce al modello proprietà uniche per il nostro scopo:

- **Comprensione Spaziale e Geometrica:** DINOv2 apprende nativamente la geometria della scena, il layout spaziale e la profondità, catturando l'atmosfera globale della stanza piuttosto che limitarsi a riconoscere singoli oggetti. Questo lo rende l'estrattore perfetto per distinguere stanze diverse.
- **Robustezza al Dominio Egocentrico:** Essendo basato su architettura Transformer e addestrato su matching di patch locali e globali, il modello risulta incredibilmente resiliente alle occlusioni parziali e al motion blur.

3.4.2 Pipeline di Estrazione Offline e Ottimizzazione della Memoria

Per massimizzare l'efficienza computazionale, l'estrazione delle feature è stata concepita come uno step di preprocessing *offline*. I video sono stati processati frame per frame passando le immagini attraverso la variante `dinov2_vits14` (modello Small con patch di dimensione 14). Il Vision Transformer ha restituito, per ciascun frame, un *embedding* denso di dimensione **384**. I tensori estratti, di forma $(T, 384)$ dove T è il numero di frame del video, sono stati salvati permanentemente su disco in formato `.pt` (PyTorch tensor).

La natura esplorativa continua dei video egocentrici ha imposto severe sfide ingegneristiche in fase di estrazione, in particolar modo a causa delle dimensioni di alcune sequenze di test, composte da decine di migliaia di frame. I primi approcci *naïve*, basati sull'accumulo in RAM delle feature in liste Python seguite da un `torch.stack()`, causavano catastrofici errori di *Out-Of-Memory* (OOM) sul cluster di calcolo, esaurendo in pochi secondi svariate decine di gigabyte di memoria. Per ovviare a questo problema infrastrutturale, lo script di estrazione è stato riprogettato con una complessa strategia di gestione della memoria, che prevede la pre-allocazione dei tensori e lo svuotamento esplicito della RAM ad ogni salvataggio parziale.

Inoltre, dato l'elevato tempo richiesto per l'inferenza di milioni di frame tramite DINOv2, abbiamo implementato un sistema di *resume* robusto basato su file sidecar leggeri (`_rooms.json`). Questo meccanismo ci ha garantito che, in caso di interruzioni forzate o preemption sul cluster, il processo potesse riprendere fluidamente saltando le cartelle già elaborate e ricostruendo dinamicamente le mappature delle stanze, ottimizzando al contempo l'utilizzo del filesystem di rete (NFS).

Questo approccio disaccoppiato e ingegnerizzato ad-hoc ha abbattuto drasticamente i tempi di addestramento: i successivi modelli di *sequence modeling* hanno potuto processare istantaneamente vettori semantici iper-compresi, coerenti e altamente informativi, senza dover ricalcolare i pesanti gradienti del Vision Transformer ad ogni iterazione di training.

3.5 Modellazione Temporale con Mamba

Risolto il problema dell'estrazione visiva, la sfida successiva consisteva nel modellare l'evoluzione temporale della visita. A tal fine, abbiamo adottato l'architettura **Mamba** [5], un modello emergente basato sugli *State Space Models* (SSM) che offre la stessa capacità espressiva dei Transformer nell'individuare relazioni a lungo raggio, ma scalando in complessità lineare ($\mathcal{O}(N)$) rispetto alla lunghezza della sequenza, qualità indispensabile per elaborare interi video di migliaia di frame in memoria GPU.

Per garantire la convergenza senza incorrere in saturazioni della memoria VRAM sul cluster (considerando sequenze massime superiori ai 3000 frame per batch), l'architettura è stata meticolosamente dimensionata: un d_model pari a 256, 4 layer Mamba sequenziali, d_state fissato a 16 e un Dropout del 20%, addestrati con una *batch size* di 4.

Il nostro processo di ottimizzazione temporale ha attraversato tre iterazioni principali (V1, V2 e V3), per far fronte alle problematiche intrinseche di Palazzo Bellomo.

3.5.1 Modello V1: Mamba Base

Nel primo esperimento abbiamo addestrato l'architettura Mamba pura, ottimizzata tramite una `CrossEntropyLoss` standard.

- **Risultato:** La rete ha ottenuto un FF1 pari a ~ 0.8098 (in linea col paper) ma un ASF1 di soli ~ 0.4079 (drasticamente inferiore).
- **Criticità:** A causa del grave sbilanciamento delle classi nel set di training, la loss non pesata portava il modello a ignorare del tutto gli ambienti meno frequenti, ottenendo 0% di accuratezza su molte stanze. Inoltre, la pura inferenza per-frame ha causato un forte flickering, abbassando notevolmente l'ASF1.

3.5.2 Modello V2: Weighted Loss e Label Smoothing

Per ovviare al problema dello sbilanciamento, abbiamo introdotto una **Weighted Loss**: la funzione `CrossEntropyLoss` è stata pesata inversamente rispetto alla frequenza dei frame per ogni classe. Inoltre, abbiamo applicato il *Label Smoothing* (impostato a 0.1) per evitare un'eccessiva sicurezza del modello, mitigando l'overfitting.

A valle della rete, per stabilizzare temporalmente l'output e correggere il flickering, abbiamo utilizzato un Filtro Mediano. Piuttosto che affidarci a un iperparametro statico, abbiamo ingegnerizzato lo script di valutazione per eseguire autonomamente una ricerca empirica (*grid search*) sulla dimensione del kernel del filtro, scansionando finestre temporali da 1 fino a oltre 3000 frame. Questa ottimizzazione dinamica ha permesso di individuare matematicamente il kernel ottimale (nel nostro caso 501 frame, corrispondenti a circa 16 secondi di video) che massimizzasse la complessa metrica ASF1.

- **Risultati:** **FF1 = 0.8572** (+4.72% sul paper) e **ASF1 = 0.6194** (+2.94% sul paper).
- **Conclusioni:** Obiettivo raggiunto e superato. La V2 ha ripristinato l'accuratezza sulle classi di minoranza e, grazie alla ricerca automatica del miglior kernel di smoothing, si è imposta come soluzione ideale per massimizzare la coerenza temporale (ASF1).

3.5.3 Modello V3 Experimental: MS-TCN e MLP

Con l'intento di rimuovere la dipendenza dal post-processing manuale (il filtro mediano) ed estrarre la massima precisione possibile, abbiamo progettato un'evoluzione *end-to-end*. La V3 introduce:

- Un **Multi-Layer Perceptron (MLP)** in ingresso (Lineare $\rightarrow$ GELU $\rightarrow$ Lineare) per una proiezione più espressiva delle feature di DINOv2.
- Una testa di classificazione basata su **Multi-Stage Temporal Convolutional Network (MS-TCN)** con convoluzioni dilatate (kernel 3, dilation 1, 2, 4, 8) in puro PyTorch, permettendo al modello di imparare nativamente lo smoothing guardando i frame adiacenti durante il training.
- **Risultati:** **FF1 = 0.8718** (+6.18% sul paper) e **ASF1 = 0.5815**.
- **Analisi del Trade-off:** La V3 ha raggiunto uno sbalorditivo FF1 vicino al 90%, dimostrando una capacità superba di interpretare l'ambiente frame per frame (superando lo stato dell'arte). L'ASF1 è leggermente calato rispetto alla V2 poiché il campo recettivo della nostra MS-TCN a 4 layer (31 frame, circa 1 secondo) non era sufficientemente ampio da livellare transizioni lente (10-15 secondi), compito nel quale il filtro mediano da 501 frame eccelleva.

3.6 Discussione

I risultati conseguiti dimostrano l'inadeguatezza degli approcci statici (VGG19) per il task di Room Localization, evidenziando la forza delle architetture di sequence modeling come Mamba. La nostra ricerca ha prodotto due modelli complementari: la **V2** (il campione di stabilità temporale, con il miglior ASF1) e la **V3** (il campione di classificazione pura, con il miglior FF1 assoluto), fornendo un'analisi completa sul trade-off tra smoothing post-processing (filtri larghi) e smoothing neurale (convoluzioni temporali con campo recettivo limitato).

Capitolo 4

Task 2 — Point of Interest Recognition

4.1 Definizione del Problema

Il Task 2, denominato *Point of Interest Recognition*, consiste nel rilevare e classificare i Punti di Interesse (POI) all'interno di frame estratti da video egocentrici. Si tratta di un problema di **object detection**: per ogni frame il modello deve predire un insieme di bounding box, ciascuna associata alla classe del POI corrispondente, nella forma $(x_{\text{center}}, y_{\text{center}}, w, h, \text{class})$.

A differenza dei task 1 e 3, che operano rispettivamente a livello di classificazione globale del frame e di matching tra embedding, il Task 2 richiede una localizzazione spaziale fine-grained degli oggetti di interesse, rendendo necessario l'impiego di architetture specifiche per la detection.

4.2 La Baseline del Paper Originale

4.2.1 Architettura e Protocollo

Gli autori del dataset EGO-CH hanno adottato **YOLOv3** [2] (Redmon e Farhadi, 2018) come baseline per il Task 2, motivando la scelta con le performance in tempo reale e la popolarità dell'architettura nel dominio del patrimonio culturale [1].

YOLOv3 è un detector *single-stage* basato su *anchor boxes*, con un backbone **Darknet-53** da circa 61 milioni di parametri. Le caratteristiche salienti della configurazione adottata nel paper sono:

- **Anchor boxes**: vengono utilizzate le anchor standard fornite dagli autori per il dataset COCO, senza ricalcolo specifico per il dominio egocentrico.
- **Soglia di detection**: ottimizzata per ciascun sito culturale sul validation set tramite grid search nel range $[5 \times 10^{-4}; 0.40]$:
 - Palazzo Bellomo: soglia = 0.01, learning rate = 0.001
 - Monastero dei Benedettini: soglia = 0.001, learning rate = 0.01
- **Metrica di valutazione**: **mean Average Precision (mAP)** con soglia IoU pari a 0.5 (equivalente a mAP@50), mediata su tutti i video di test.

4.2.2 Risultati del Paper (Tabella 4)

I risultati riportati nella Tabella 4 del paper originale sono:

Tabella 4.1: Risultati della baseline YOLOv3 dal paper EGO-CH [1] (Tabella 4).

Sito Culturale	mAP@50
Palazzo Bellomo (191 POI)	10.59%
Monastero dei Benedettini (35 POI)	15.45%

4.2.3 Analisi delle Difficoltà Evidenziate

Gli autori stessi riconoscono che i punteggi sono «in general very low», e identificano le seguenti cause principali:

1. **Natura atipica dei POI:** i punti di interesse non sono solo oggetti ben definiti (quadri, sculture), ma includono **elementi architettonici** come pavimenti, corridoi e scale — intrinsecamente difficili da delimitare con bounding box.
2. **Riconoscimento a livello di istanza:** a differenza dei benchmark classici di object detection (COCO, VOC), dove le classi sono categorie semantiche ampie (es. “cane”, “auto”), qui il modello deve discriminare tra *istanze* diverse dello stesso tipo di oggetto (es. quadri diversi in stanze diverse).
3. **Motion blur estremo:** i movimenti rapidi della testa del visitatore producono artefatti di sfocatura che degradano significativamente le feature estratte dal backbone.
4. **Variazioni di illuminazione:** il dataset del Monastero è stato raccolto nell’arco di 3 mesi, con condizioni di luce radicalmente diverse.
5. **Disparità tra siti:** Palazzo Bellomo, con 191 POI, risulta drasticamente più difficile del Monastero (35 POI), come confermato dal gap di 5 punti percentuali nella mAP.

4.3 La Nostra Proposta: YOLOv8

4.3.1 Motivazione della Scelta Architettureale

Per affrontare questo task abbiamo scelto di utilizzare **YOLOv8** [3] (Ultralytics, 2023) in sostituzione del più datato YOLOv3 (2018) impiegato nel paper originale.

La famiglia di modelli YOLO (*You Only Look Once*) è celebre nell’ambito della computer vision per la sua capacità di individuare e classificare gli oggetti presenti in un’immagine in un unico passaggio, garantendo un’elevata velocità di esecuzione. Le motivazioni principali che ci hanno spinto verso la versione 8 sono le seguenti:

1. **Maggiore accuratezza ed efficienza:** YOLOv8 rappresenta lo stato dell’arte moderno della rete. A parità di risorse computazionali, riesce a estrarre caratteristiche visive molto più ricche e dettagliate rispetto a YOLOv3.
2. **Rilevamento senza griglie predefinite (Anchor-Free):** i modelli tradizionali come YOLOv3 dovevano basarsi su forme di rettangoli predefinite (chiamate *anchor box*) per tentare di indovinare dove si trovassero gli oggetti. YOLOv8 elimina questo vincolo rigido e impara a ritagliare direttamente i bordi degli oggetti, risultando molto più preciso quando si tratta di individuare elementi architettonici o forme irregolari.

3. **Capacità di distinguere oggetti simili:** grazie all'architettura riprogettata, la rete è in grado di distinguere meglio i dettagli fini tra oggetti semanticamente o visivamente molto simili (come quadri differenti o dettagli murali).
4. **Scalabilità dei modelli:** YOLOv8 offre diverse dimensioni di rete (da *Nano* fino a *X-Large*). Questo ci ha permesso di condurre un confronto diretto tra un modello leggerissimo (adatto a dispositivi mobili) e uno ad altissima capacità per il massimo della precisione.

4.3.2 Approccio End-to-End

A differenza dei Task 1 e 3, in cui le feature visive vengono estratte offline tramite un foundation model (DINOv2) e poi elaborate da classificatori o metriche di similarità a valle, nel Task 2 si adotta un approccio completamente **end-to-end**: il modello YOLOv8 opera direttamente sulle immagini raw ad alta risoluzione, estraendo internamente le feature tramite il proprio backbone convoluzionale e producendo le predizioni di detection in un unico passaggio forward.

Questa scelta è motivata dal fatto che i detector moderni come YOLOv8 sono progettati per apprendere rappresentazioni spazialmente localizzate, ottimizzate congiuntamente per la regressione delle bounding box e la classificazione — una proprietà che si perderebbe con un'estrazione di feature generiche pre-calcolate.

4.4 Pipeline Implementativa

4.4.1 Fase 1: Preprocessing e Riformattazione del Dataset

Il dataset EGO-CH presenta una **struttura eterogenea** tra i due siti culturali, che ha richiesto una fase di riformattazione non banale:

- **Palazzo Bellomo:** struttura piatta, con immagini e annotazioni (file `.txt` con bounding box in formato YOLO) raggruppate in cartelle separate ma con nomi corrispondenti.
- **Monastero dei Benedettini:** struttura gerarchica profonda, con immagini e annotazioni annidate per POI specifico (es. `Training/5_Antirefettorio/5.3_POI_nome/`).

Lo script `task2_format_yolo.py` è stato sviluppato per unificare queste strutture in un formato compatibile con YOLOv8:

1. **Scansione ricorsiva:** il dataset sorgente viene esplorato con `rglob` per individuare tutte le immagini (`.jpg`, `.jpeg`, `.png`) e i file di annotazione (`.txt`).
2. **Associazione immagine-label:** per ogni immagine viene cercato un file `.txt` con lo stesso *stem* (nome senza estensione). Solo le coppie valide vengono mantenute.
3. **Split randomizzato:** le coppie valide vengono mescolate con seed fissato (`seed = 42`) e suddivise in training (80%), validation (10%) e test (10%).
4. **Copia nella struttura YOLO:** le immagini e le label vengono copiate nelle rispettive sottocartelle:

```
yolo_dataset/  
+-- images/  
|   +-- train/  
|   +-- val/
```

```

|   +-- test/
+-- labels/
|   +-- train/
|   +-- val/
|   +-- test/
+-- dataset.yaml

```

5. **Generazione automatica del file dataset.yaml:** viene creato il file di configurazione richiesto da YOLOv8, contenente i percorsi delle cartelle, il numero di classi (dedotto dal class ID massimo nelle annotazioni) e i nomi delle classi.

La Figura 4.1 mostra la distribuzione delle istanze per classe e delle bounding box nel dataset formattato: si nota una marcata *long-tail distribution*, con poche classi dominanti e numerose classi con pochissime istanze.




Figura 4.1: Distribuzione delle istanze per classe (in alto a sinistra), distribuzione spaziale dei centri delle bounding box (in basso a sinistra) e distribuzione delle dimensioni (larghezza vs. altezza, in basso a destra). Si nota la forte disomogeneità tra le classi e la predominanza di bounding box di grandi dimensioni, tipiche dei POI architettonici.

4.4.2 Fase 2: Training

L'addestramento è stato eseguito su un cluster HPC del Dipartimento di Matematica e Informatica (DMI) dell'Università di Catania, utilizzando GPU NVIDIA L40S tramite il sistema di job scheduling SLURM e il container runtime Apptainer.

Lo script `task2_train_yolo.py` sfrutta l'API della libreria `ultralytics` per configurare e lanciare l'addestramento caricando i pesi pre-addestrati sul dataset COCO.

La configurazione del job SLURM è stata definita nello script `run_task2_yolo.sh`, con le seguenti risorse allocate:

- 1 GPU NVIDIA L40S (22 GB VRAM allocati tramite `gres=shard`)
- 32 GB di RAM di sistema
- Timeout massimo di 12 ore

4.5 Esperimenti e Risultati

Sono stati condotti due esperimenti principali variando la capacità dell’architettura detector, al fine di analizzare in modo rigoroso il trade-off tra efficienza computazionale ed accuratezza di localizzazione.

4.5.1 Setup Sperimentale

Per valutare la scalabilità delle prestazioni, abbiamo configurato due run sperimentali sulla base dei modelli **YOLOv8n** (*Nano*, ~ 3.3 M parametri) e **YOLOv8x** (*X-Large*, ~ 68.3 M parametri). Entrambe le reti sono state inizializzate con pesi pre-addestrati sul benchmark COCO e ri-addestrate end-to-end sul dataset EGO-CH. La Tabella 4.2 sintetizza la configurazione e gli iperparametri adottati.

Tabella 4.2: Configurazione degli esperimenti condotti per il Task 2.

Parametro	Run 1 (Nano)	Run 2 (X-Large)
Architettura	YOLOv8n	YOLOv8x
Pesi iniziali	yolov8n.pt (COCO)	yolov8x.pt (COCO)
Parametri	~ 3.3 M	~ 68.3 M
Epoche massime	100	300
Batch size	32	16
Risoluzione input	640×640	640×640
Optimizer	Auto (SGD)	Auto (SGD)
Learning rate (lr_0)	0.01	0.01
Data augmentation	Mosaic, RandAugment, Erasing	Mosaic, RandAugment, Erasing
Early stopping	Patience = 100	Patience = 100

4.5.2 Risultati Quantitativi

La valutazione quantitativa sui dati di test del Monastero dei Benedettini conferma la drastica superiorità dell’approccio anchor-free basato su YOLOv8 rispetto alla baseline del paper originale. La Tabella 4.3 riporta le metriche principali, mentre la Tabella 4.4 riassume i miglioramenti percentuali relativi ottenuti.

Tabella 4.3: Confronto delle performance di Object Detection sul Monastero dei Benedettini (la metrica mAP@50 consente il confronto diretto con la baseline YOLOv3). Vengono riportate anche le metriche COCO-style mAP@[50:95].

Metrica	Baseline YOLOv3 [1]	YOLOv8n (Nano)	YOLOv8x (X-Large)
mAP@50	15.45%	19.92%	29.70%
mAP@[50:95]	—	14.82%	24.30%
Precision	—	0.489	0.685
Recall	—	0.218	0.298
Parametri	~61 M	~3.3 M	~68.3 M
Epoche effettive	—	100/100	269/300 (early stop)
Tempo di training	—	~1.6 ore	~7.2 ore

Tabella 4.4: Incrementi relativi della mAP@50 rispetto alla baseline YOLOv3 del paper originale (15.45%).

Modello	mAP@50	Δ relativo vs. Baseline
Baseline YOLOv3 (Paper)	15.45%	—
YOLOv8n (Nano)	19.92%	+ 28.9%
YOLOv8x (X-Large)	29.70%	+ 92.2%

4.5.3 Curve di Addestramento

L'analisi dell'andamento delle funzioni di perdita (*box loss*, *classification loss*, *distribution focal loss*) e delle metriche di validazione fornisce utili indicazioni sulla dinamica di convergenza dei due modelli. La Figura 4.2 mostra l'evoluzione per il modello Nano, mentre la Figura 4.3 illustra l'addestramento della rete X-Large.




Figura 4.2: Curve di addestramento del modello YOLOv8n (Nano, 100 epoche). Le loss di training (box, cls, dfl) mostrano una convergenza regolare, mentre le metriche di validazione (mAP@50 e mAP@50-95) evidenziano un aumento costante fino all'ultima epoca, suggerendo che il modello avrebbe potuto beneficiare di un addestramento più lungo.




Figura 4.3: Curve di addestramento del modello YOLOv8x (X-Large, 269 epoche su 300 massime). Si osserva una convergenza più lenta ma più ricca: le loss di validazione raggiungono un plateau intorno all’epoca 100, mentre le metriche mAP continuano a crescere fino all’epoca ~ 170 , dopo la quale il meccanismo di early stopping (patience = 100) arresta l’addestramento all’epoca 269.

4.5.4 Analisi Qualitativa

Per verificare l’efficacia pratica della localizzazione, la Figura 4.4 propone un confronto affiancato tra le annotazioni manuali di *ground truth* e le predizioni generate dal modello YOLOv8x su un batch di immagini di validazione. Si nota la capacità della rete di isolare POI complessi anche in presenza di forte prospettiva ed ambienti poco illuminati.




Figura 4.4: Confronto qualitativo tra ground truth (a) e predizioni YOLOv8x (b) su un batch di validazione. Le bounding box colorate indicano le classi dei POI. Si noti la varietà delle scene: archi, porte, pavimenti maiolicati, ambienti bui — tutti elementi tipici della sfida egocentrica in contesti culturali.

4.5.5 Matrice di Confusione

Per studiare il comportamento per-classe del detector e identificare eventuali sbilanciamenti, la Figura 4.5 illustra la matrice di confusione normalizzata per il modello YOLOv8x. Si osserva la pronunciata sparsità della diagonale, dovuta alla prevalenza di classi dominanti a discapito di quelle rare.




Figura 4.5: Matrice di confusione normalizzata del modello YOLOv8x. La forte sparsità della matrice riflette il numero elevatissimo di classi (>60) e la distribuzione long-tail del dataset: solo poche classi ben rappresentate (class_15, class_16, class_57) mostrano attivazioni significative sulla diagonale, mentre la maggior parte delle classi rare non viene mai predetta.

4.6 Discussione

4.6.1 Confronto con la Baseline del Paper

Il confronto con la baseline del paper originale rivela due risultati significativi:

YOLOv8n supera la baseline con $20\times$ meno parametri. Il modello Nano ha ottenuto un mAP@50 di **19.92%**, superiore del **+28.9%** rispetto al 15.45% di YOLOv3, pur disponendo di soli 3.3M di parametri contro i 61M del baseline. Questo risultato dimostra che le innovazioni architetturali di YOLOv8 (come l'approccio anchor-free e la struttura modernizzata) non solo compensano la riduzione drastica di capacità, ma portano a un netto miglioramento delle performance.

Il modello Nano risulta particolarmente adatto a scenari di deployment in tempo reale su dispositivi edge (es. visori HoloLens, smartphone), dove la potenza computazionale e il consumo energetico sono vincoli stringenti.

YOLOv8x raddoppia le performance della baseline. Il modello X-Large ha raggiunto un mAP@50 di **29.70%**, segnando un incremento relativo del **+92.2%** rispetto alla baseline. L'analisi dettagliata evidenzia:

- **Risoluzione dell'ambiguità visiva:** l'architettura anchor-free, combinata con il backbone CSPDarknet a piena capacità, ha permesso al modello di discriminare efficacemente tra POI visivamente simili.
- **Performance per classe non uniformi:** la rete X-Large ha raggiunto precisioni quasi perfette su classi ben rappresentate (es. Class_16: mAP 95.2%, Class_15: mAP 82.4%), mentre le classi con poche istanze o alta ambiguità visiva restano problematiche. Questa distribuzione long-tail è un limite intrinseco del dataset.

- **Early stopping funzionale:** l'addestramento si è arrestato automaticamente all'epoca 269 (su un massimo di 300), indicando che il modello ha raggiunto la convergenza intorno all'epoca 169 senza overfitting distruttivo.
- **Robustezza al motion blur:** la maggiore capacità di estrazione delle feature del backbone X-Large ha permesso di gestire il motion blur tipico dei video egocentrici in modo significativamente più robusto rispetto a YOLOv3.

4.6.2 Nota sulla Comparabilità delle Metriche

È importante sottolineare che il paper originale riporta la metrica **mAP@50** (IoU threshold = 0.5), che è la metrica standard per YOLOv3. I nostri risultati vengono riportati sia in formato mAP@50 (per il confronto diretto) sia nel formato COCO-style **mAP@[50:95]** (media su 10 soglie IoU da 0.5 a 0.95 con passo 0.05), che è lo standard moderno e produce valori sistematicamente inferiori in quanto più stringente. Il confronto diretto sulla metrica mAP@50 è il più corretto e mostra il miglioramento nella sua interezza.

4.6.3 Trade-off Efficienza–Accuratezza

Il confronto tra i due modelli mette in luce un chiaro trade-off:

- Se l'obiettivo è l'**accuratezza massima** per una valutazione accademica o per un sistema di analisi offline, **YOLOv8x** stabilisce il nuovo stato dell'arte con un margine netto.
- Se l'obiettivo prevede il **deployment su dispositivi indossabili** con risorse limitate, **YOLOv8n** offre un compromesso eccezionale, superando la precisione del baseline originale con una frazione dei parametri e un'inferenza in tempo reale.

Capitolo 5

Task 3 — Object Retrieval

5.1 Definizione del Problema

Il Task 3, denominato *Object Retrieval*, consiste nel recuperare l'immagine di riferimento di uno specifico Punto di Interesse (POI) da un database (Gallery), a partire da un'immagine di *query* ritagliata che contiene il medesimo oggetto.

Nel contesto della *Egocentric Vision* applicata ai beni culturali, questo task riveste una notevole rilevanza pratica: permette infatti l'identificazione automatica e il recupero di schede informative relative a un'opera d'arte quando la fase di *object detection* può essere bypassata — ad esempio quando il visitatore inquadra spontaneamente l'opera ponendola al centro del campo visivo del visore indossabile o dello smartphone. Inoltre, come evidenziato nei capitoli precedenti, il rilevamento spaziale preciso dei POI (Task 2) rappresenta una sfida estremamente complessa; l'Object Retrieval offre pertanto una formulazione alternativa e complementare focalizzata direttamente sul matching visivo.

5.1.1 Formulazione One-Shot Retrieval

In conformità con il protocollo sperimentale definito nel benchmark EGO-CH [1], abbiamo concentrato le nostre analisi sulla formulazione più critica e sfidante: il **One-Shot Retrieval**. In questa variante:

- **Gallery (Database di Riferimento)**: contiene esclusivamente le immagini di riferimento pulite e ufficiali associati a ciascun POI (una sola immagine per ogni classe). Tali immagini provengono dalla cartella **Training/** di ciascun sito culturale.
- **Query (Set di Test)**: è costituito dall'insieme di tutte le patch visive ritagliate dai bounding box annotati nei video di visita egocentrica (contenute nella cartella **Test/**). Nello specifico, si tratta di **23.727 patch** per Palazzo Bellomo e **44.978 patch** per il Monastero dei Benedettini.

5.1.2 Le Sfide del Domain Shift

La formulazione One-Shot introduce due insidie fondamentali:

1. **Estrema scarsità di campioni etichettati**: il modello ha a disposizione una sola immagine di esempio per ciascuna classe nella Gallery per apprendere o confrontare la rappresentazione dell'oggetto.
2. **Marcato Domain Shift (Disallineamento di Dominio)**: esiste una drastica differenza qualitativa e geometrica tra le immagini della Gallery (fotografie da

catalogo professionale, ben illuminate, perfettamente a fuoco e frontali) e le immagini Query (ritagli di fotogrammi egocentrici caratterizzati da sfocature da movimento, occlusioni parziali, prospettive angolate, riflessi e variazioni estreme di luce ambientale).

5.2 La Baseline del Paper Originale

5.2.1 Architettura e Metodologia

Nella baseline proposta dagli autori di EGO-CH [1], l'estrazione delle caratteristiche visive dalle patch viene affidata a una rete **VGG19** pre-addestrata in modo supervisionato su ImageNet. Le feature vengono prelevate dal penultimo strato fully-connected (**FC7**), ottenendo vettori di rappresentazione a 4096 dimensioni.

Il matching tra la query e le immagini del database viene eseguito mediante l'algoritmo **K-Nearest Neighbors (K-NN)** con $K = 1$, misurando la vicinanza nello spazio euclideo delle feature estratte.

5.2.2 Risultati del Paper (Tabella 5)

La Tabella 5.1 riassume i risultati ottenuti dalla baseline VGG19 nella variante One-Shot per i due siti culturali, così come riportati nella Tabella 5 del paper originale.

Tabella 5.1: Risultati della baseline VGG19 (FC7 + 1-NN) dal paper EGO-CH [1] per il One-Shot Retrieval (Tabella 5).

Sito Culturale	Precision	Recall	F1 Score
Monastero dei Benedettini (35 POI)	0.290	0.070	0.080
Palazzo Bellomo (191 POI)	0.004	0.007	0.001

5.2.3 Criticità della Baseline

I risultati evidenziano come la baseline basata su VGG19 fallisca nel gestire l'impatto del One-Shot Retrieval:

- Nel **Monastero dei Benedettini**, nonostante il contenuto numero di classi (35 POI), la F1 Score si arresta a un modestissimo 0.080, penalizzata da una Recall bassissima (0.070).
- A **Palazzo Bellomo**, con 191 POI visivamente simili, la baseline crolla completamente a una F1 Score pari a 0.001, valore pressoché indistinguibile dalla scelta casuale ($1/191 \approx 0.005$). Ciò dimostra la totale incapacità delle feature **FC7** di VGG19 di superare il *domain shift* e discriminare tra istanze di opere d'arte in presenza di un solo campione di riferimento.

5.3 La Nostra Proposta: DINOv2 e Matching Latente

5.3.1 Motivazione dell'Estrattore Vision Transformer

Per superare i limiti strutturali della baseline convoluzionale, abbiamo progettato una pipeline basata sul foundation model **DINOv2** (`dinov2_vits14`) [4].

A differenza delle CNN tradizionali addestrate per classificazione supervisionata su ImageNet (che tendono a concentrarsi su scorciatoie tessiturali o sull'oggetto dominante della classe), DINOv2 viene addestrato con tecniche di *Self-Supervised Learning* (SSL) che incoraggiano la rete ad apprendere concetti semantici e geometrici profondi. Le motivazioni chiave per l'adozione di DINOv2 nel retrieval One-Shot sono:

1. **Invarianza alle Trasformazioni visive:** gli obiettivi di apprendimento auto-supervisionato di DINOv2 garantiscono che l'embedding di un oggetto rimanga stabile nello spazio latente anche in presenza di variazioni di scala, illuminazione, sfocatura o punto di vista.
2. **Rappresentazione Densa e Compatta:** la variante `dinov2_vits14` (Vision Transformer Small con patch da 14×14 pixel) genera per ogni patch un vettore descrittore denso di dimensione **384**, drasticamente più compatto rispetto ai 4096 valori di VGG19 FC7.

5.3.2 Metriche di Matching: Cosine Similarity

In luogo di un classificatore supervisionato a valle o di una distanza euclidea semplice, il matching tra la query egocentrica e l'insieme delle immagini della Gallery viene calcolato direttamente nello spazio latente di DINOv2 tramite la **Cosine Similarity**:

$$\text{sim}(\mathbf{q}, \mathbf{g}_i) = \frac{\mathbf{q} \cdot \mathbf{g}_i}{\|\mathbf{q}\|_2 \|\mathbf{g}_i\|_2} \quad (5.1)$$

dove $\mathbf{q} \in \mathbb{R}^{384}$ rappresenta l'embedding della patch Query ed $\mathbf{g}_i \in \mathbb{R}^{384}$ è l'embedding dell' i -esimo elemento della Gallery. Per ciascuna query, l'etichetta predetta corrisponde al POI dell'immagine in Gallery che massimizza la similitudine coseno:

$$\hat{y} = \arg \max_i \text{sim}(\mathbf{q}, \mathbf{g}_i) \quad (5.2)$$

Questo approccio sfrutta l'orientamento dei vettori nello spazio delle caratteristiche di DINOv2, risultando insensibile alle variazioni di norma indotte da differenze di contrasto o luminosità tra le immagini.

5.4 Pipeline Implementativa

La pipeline di Object Retrieval è stata strutturata in script Python modulari, progettati per garantire l'esecuzione efficiente su architetture HPC (cluster GCluster dell'Università di Catania):

1. `task3_extract_patch_features.py`:
 - Riceve in ingresso il percorso delle patch ritagliate (`patches_dir`) e il file di output `.pt`.

- Ridimensiona le immagini alla risoluzione di 224×224 e applica le trasformazioni di normalizzazione standard di ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$).
- Carica il modello `dinov2_vits14` in modalità offline e disabilita il calcolo dei gradienti (`torch.no_grad()`).
- Estrae i vettori latenti a 384 dimensioni per tutte le immagini della Gallery e delle Query, salvando su disco un dizionario PyTorch contenente l'associazione `percorso_relativo` $\rightarrow$ `tensore`.

2. `task3_evaluate_retrieval.py`:

- Carica i file delle feature estratte (`gallery_features.pt` e `query_features.pt`) unitamente alle etichette ufficiali (`labels.txt`).
- Associa a ciascun frame di query la relativa etichetta di *ground truth* leggendo le annotazioni contenute nella cartella `Test/labels`.
- Calcola in maniera massiva e vettorizzata la matrice di Cosine Similarity di forma $N_{\text{queries}} \times N_{\text{gallery}}$ sfruttando le funzioni ottimizzate di `scikit-learn`.
- Valuta le metriche di accuratezza e le metriche pesate (*weighted*) di Precision, Recall e F1 Score per un confronto diretto con la letteratura.

3. Script di Orchestrazione SLURM (`run_task3.sh` / `task3.sh`):

- Automatizzano l'esecuzione della pipeline su nodi computazionali dotati di GPU NVIDIA L40S all'interno di ambienti containerizzati Apptainer.

5.5 Esperimenti e Risultati

La Tabella 5.2 riporta il confronto sistematico tra la baseline VGG19 pubblicata nel paper EGO-CH e la nostra soluzione basata su DINOv2 per entrambi i siti culturali nella formulazione One-Shot Retrieval.

Tabella 5.2: Confronto delle performance di One-Shot Retrieval tra la baseline VGG19 del paper EGO-CH [1] e la nostra architettura DINOv2 (`dinov2_vits14` + Cosine Similarity).

Sito / Modello	Precision	Recall	F1 Score	Accuracy
Monastero dei Benedettini (35 POI)				
Baseline VGG19 (Paper)	0.2900	0.0700	0.0800	—
Nostro Modello (DINOv2)	0.5353	0.3369	0.3752	0.3369
<i>Incremento Relativo</i>	<i>+84.6%</i>	<i>+381.3%</i>	<i>+369.0%</i>	—
Palazzo Bellomo (191 POI)				
Baseline VGG19 (Paper)	0.0040	0.0070	0.0010	—
Nostro Modello (DINOv2)	0.2194	0.1643	0.1512	0.1643
<i>Incremento Relativo</i>	<i>+54.8×</i>	<i>+23.5×</i>	<i>+151.2×</i>	—

5.6 Discussione e Analisi Comparativa

L'analisi comparativa dei risultati sperimentali permette di trarre importanti conclusioni di carattere metodologico e architettureale.

5.6.1 Risoluzione del Domain Shift mediante SSL

Il risultato di maggior rilievo è rappresentato dall'incredibile incremento delle prestazioni ottenuto su entrambi i dataset:

- Nel **Monastero dei Benedettini**, DINOv2 fa registrare un aumento della F1 Score da 0.0800 a 0.3752 (un fattore di incremento pari a quasi $5\times$), raddoppiando contestualmente la Precision (0.5353 vs 0.2900).
- A **Palazzo Bellomo**, la baseline VGG19 soffriva un crollo catastrofico ($F1 = 0.0010$), rendendo il task sostanzialmente inaffrontabile. DINOv2 eleva la F1 Score al 15.12% (0.1512), con un incremento superiore a 150 **volte**.

Questi miglioramenti confermano l'ipotesi che la rappresentazione latente di DINOv2 sia intrinsecamente immune alle discrepanze di dominio. Le caratteristiche visive estratte da VGG19, legate a filtri convoluzionali rigidi addestrati su classi ImageNet ad alto livello, falliscono nel momento in cui devono confrontare una fotografia di catalogo ideale con un ritaglio egocentrico sfocato e angolato. Al contrario, l'architettura Vision Transformer di DINOv2 apprende mappe di attenzione locali e globali che isolano le strutture geometriche invarianti dell'opera d'arte.

5.6.2 Efficienza Computazionale e Spaziale

Oltre alla drastica superiorità in accuratezza, l'approccio proposto si dimostra notevolmente più efficiente dal punto di vista infrastrutturale:

- **Dimensione dei Vettori:** il passaggio da vettori a 4096 dimensioni (VGG19 FC7) a vettori da 384 dimensioni (DINOv2 ViT-S/14) comporta una **riduzione dell'occupazione di memoria superiore al 90%** sia su disco che in RAM VRAM.
- **Velocità di Matching:** la riduzione della dimensionalità consente di calcolare le matrici di Cosine Similarity tra decine di migliaia di vettori di query (> 44.000 patch nel Monastero) e il database della Gallery in pochi millisecondi su architetture hardware standard, rendendo il sistema adatto all'impiego in tempo reale su dispositivi wearable.

5.6.3 Impatto della Scalabilità e della Complessità dei Siti

Infine, i risultati evidenziano la netta differenza di difficoltà tra i due contesti culturali. Palazzo Bellomo presenta un numero di POI oltre 5 volte superiore rispetto al Monastero (191 vs 35 classi), molti dei quali visivamente simili (es. dipinti sacri dello stesso periodo storico o con soggetti analoghi). Nonostante la complessità intrinseca di Palazzo Bellomo mantenga i punteggi assoluti inferiori rispetto al Monastero, l'adozione di DINOv2 dimostra che una rappresentazione latente auto-supervisionata consente di estrarre un segnale discriminativo affidabile anche in scenari ad elevata cardinalità di classe.

Capitolo 6

Conclusioni

La presente ricerca ha affrontato in maniera organica e approfondita i tre task fondamentali introdotti dal benchmark **EGO-CH** per la comprensione automatica del comportamento del visitatore in siti culturali mediante visione egocentrica.

Per ciascun task, l'adozione di metodologie di Deep Learning di ultima generazione ha consentito di superare in modo netto le baseline pubblicate nel paper originale di Ragusa et al. (2020):

1. **Task 1 — Room-based Localization:** la combinazione delle feature visive di DINOv2 con l'architettura di sequence modeling **Mamba** (State Space Model) ha permesso di modellare la continuità temporale della visita. L'introduzione della loss pesata, del label smoothing e dell'ottimizzazione dinamica del filtro mediano ha condotto al raggiungimento di un **FF1 di 0.8572** e di un **ASF1 di 0.6194** (modello V2), superando lo stato dell'arte sia a livello di singolo frame che di coerenza sequenziale.
2. **Task 2 — Point of Interest Recognition:** la sostituzione dell'architettura legacy YOLOv3 con il moderno detector anchor-free **YOLOv8** ha prodotto progressi straordinari. Il modello leggero **YOLOv8n** ha superato la baseline con un $20\times$ in meno di parametri (19.92% mAP@50), mentre il modello a piena capacità **YOLOv8x** ha quasi raddoppiato la precisione della baseline raggiungendo un **mAP@50 del 29.70%** (+92.2% relativo).
3. **Task 3 — Object Retrieval:** la sostituzione dell'estrattore VGG19 con il foundation model **DINOv2** accoppiato alla similarità coseno nello spazio latente ha risolto in modo radicale il problema del *Domain Shift* nel regime One-Shot. I risultati hanno registrato un incremento della F1 Score di quasi $5\times$ sul Monastero dei Benedettini (0.3752) e di oltre $150\times$ su Palazzo Bellomo (0.1512), stabilendo un nuovo punto di riferimento per il retrieval One-Shot in contesti egocentrici.

In conclusione, le evidenze sperimentali raccolte confermano che l'integrazione di foundation model basati su Vision Transformer (DINOv2), modelli temporali a spazio di stato (Mamba) e object detector anchor-free di ultima generazione (YOLOv8) permette di compiere un salto qualitativo decisivo nell'analisi di video egocentrici per i beni culturali, offrendo basi solide e ad alte prestazioni per lo sviluppo di guide intelligenti e sistemi d'assistenza di nuova generazione.

Bibliografia

- [1] F. Ragusa, A. Furnari, S. Battiato, G. Signorello, G. M. Farinella, *EGO-CH: Dataset and Fundamental Tasks for Visitors Behavioral Understanding using Egocentric Vision*, Pattern Recognition Letters, vol. 131, pp. 150–157, 2020.
- [2] J. Redmon, A. Farhadi, *YOLOv3: An Incremental Improvement*, arXiv preprint arXiv:1804.02767, 2018.
- [3] G. Jocher, A. Chaurasia, J. Qiu, *Ultralytics YOLOv8*, <https://github.com/ultralytics/ultralytics>, 2023.
- [4] M. Oquab et al., *DINOv2: Learning Robust Visual Features without Supervision*, Transactions on Machine Learning Research, 2024.
- [5] A. Gu, T. Dao, *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*, arXiv preprint arXiv:2312.00752, 2023.